TP2 — Les joueurs du jeu en ligne

Supervisé, non supervisé et semi-supervisé sur un même problème

Cours : Intelligence artificielle 2
Prof. : Madalin Iulian Lupu
Nom(s) : _____
Remise : vendredi 23 octobre 2026, à 23 h 59

Consignes

- Travail **individuel ou en équipe de 2**.
- Tout le travail se fait dans le carnet Jupyter fourni.
- Remise par **pull request** sur votre dépôt Git, au plus tard le **vendredi 23 octobre 2026 à 23 h 59**.

1 Mise en situation

Un studio de jeu vidéo veut mieux connaître les joueurs de son jeu en ligne, pour adapter ses événements et ses récompenses. Il dispose de sept mesures sur **700 joueurs**. Pour ces 700 joueurs, une gestionnaire de communauté a examiné l'historique de chaque compte et noté son style de jeu : **occasionnel**, **compétitif** ou **explorateur**. Elle met environ 20 minutes par compte.

Le jeu compte des centaines de milliers de joueurs. Le studio veut savoir si l'intelligence artificielle peut retrouver les styles de jeu toute seule, et combien de comptes la gestionnaire doit vraiment examiner.

Colonne	Signification
`heures_semaine`	temps de jeu par semaine, en heures
`xp_semaine`	points d'expérience gagnés par semaine
`parties_classees_%`	part des parties jouées en mode classé, en %
`zones_explorees`	zones différentes de la carte visitées dans le mois
`achats_mois_$`	achats dans le jeu par mois, en $
`amis_en_ligne`	amis avec qui le joueur a joué dans le mois
`heure_connexion`	heure habituelle de connexion (0 à 23)

Les données sont simulées, mais construites pour ressembler à une situation réelle.

2 Objectifs

Ce travail vous fait appliquer, sur un **même problème**, les trois familles de modèles vues en classe :

- le **supervisé** (forêt aléatoire), quand toutes les étiquettes sont connues ;
- le **non supervisé** (K-Means, méthode du coude, ACP), quand aucune étiquette n'est utilisée ;
- le **semi-supervisé** (propagation d'étiquettes), quand seules quelques étiquettes sont connues.

Le carnet est **guidé** : chaque question vous dit son but, ce que fait la cellule et ce que vous devez faire, et il n'y a qu'un seul endroit à compléter par cellule de code. L'essentiel de la note porte sur ce que vous **observez** et sur les **conclusions** que vous en tirez : chaque question est suivie d'une cellule *Observation* qui pose quelques petites questions.

3 Matériel fourni

— `TP2_depart.ipynb` : le carnet de départ, à compléter. Les endroits à compléter dans le code sont marqués `....`

— `joueurs.csv` : les données, à placer dans le même dossier que le carnet. Ne modifiez pas ce fichier.

— Bibliothèques utilisées : `numpy`, `matplotlib`, `scikit-learn`.

4 Organisation du travail avec Git

1. Créez **un dépôt** pour votre travail (un seul par équipe), déposez-y le carnet et le fichier de données, puis invitez l'enseignant (et votre coéquipier ou coéquipière, s'il y a lieu).
2. Chaque section du carnet (1 à 5) est développée sur **sa propre branche**, puis intégrée à la branche principale par une **pull request**.
3. **En équipe de 2** : faites la section 1 ensemble, puis répartissez-vous les sections 2, 3 et 4 et indiquez-le dans le tableau *Répartition du travail* en haut du carnet. Chaque pull request est relue et approuvée par l'autre membre avant la fusion. Faites la section 5 et la déclaration d'IA ensemble.
4. La remise est une dernière pull request vers la branche principale, qui contient le carnet complet, **exécuté du début à la fin**.

La nomenclature des branches et des messages de commit doit respecter ce qui a été vu en cours. En équipe de 2, chaque membre doit avoir des commits à son nom dans l'historique.

Attention

Un carnet Jupyter se fusionne mal quand deux personnes modifient les mêmes cellules. Pour éviter les conflits :

— ne modifiez **que les cellules de votre section** ;

— avant chaque commit, effacez les sorties (*Kernel* → *Restart & Clear Output*) ;

— récupérez la dernière version de la branche principale avant de créer une nouvelle branche.

Seule la pull request finale contient le carnet avec toutes ses sorties.

5 Travail demandé

Les questions ci-dessous sont celles du carnet. Les consignes détaillées et le code de départ s'y trouvent.

Section 1 — Découvrir les données

1.1 Les classes et les mesures — Comptez les joueurs de chaque style et repérez l'ordre de grandeur de chaque mesure.

1.2 Un premier dessin — Dessinez les joueurs selon deux paires de colonnes et comparez.

Section 2 — Le supervisé : la référence

2.1 Entraîner une forêt — Entraînez une forêt aléatoire avec toutes les étiquettes et mesurez sa note sur le test.

2.2 Style par style, et le prix des étiquettes — Lisez les résultats style par style et calculez le temps qu'ont coûté les étiquettes.

Section 3 — Le non supervisé : chercher sans étiquettes

3.1 K-Means, avant et après la mise à l'échelle — Comparez les groupes trouvés sur les mesures brutes et sur les mesures mises à l'échelle.

3.2 Combien de groupes ? Le coude — Dessinez la courbe du coude et comparez le contenu des groupes avec 3 puis 4 groupes.

3.3 Décrire et dessiner les groupes — Choisissez votre nombre de groupes, décrivez chaque groupe avec ses moyennes et donnez-lui un nom ; comparez le dessin de l'ACP avec les vrais styles.

Section 4 — Le semi-supervisé : quelques étiquettes seulement

4.1 La forêt contre le semi-supervisé — Avec 3 étiquettes par style, comparez une forêt et un modèle semi-supervisé.

4.2 Combien d'étiquettes faut-il ? — Lisez la courbe des deux modèles de 1 à 20 étiquettes par style.

4.3 Une étiquette dans le petit groupe — Vérifiez d'où viennent les erreurs du semi-supervisé, et l'effet d'une seule étiquette bien choisie.

Section 5 — Conclusion

5.1 Le tableau des trois familles — Complétez le tableau avec vos résultats.

5.2 Votre recommandation au studio — En 8 à 12 lignes : quelle approche, combien de comptes examiner et lesquels, et que faire au sujet du petit groupe découvert.

Rappel

Chaque question est suivie d'une cellule *Observation* avec quelques petites questions. Répondez à chacune en une ou deux phrases, en citant vos résultats : un nombre recopié sans explication ne donne pas de points.

6 Utilisation de l'intelligence artificielle

— L'IA est **permise pour apprendre** : se faire expliquer une notion, un message d'erreur.

— L'IA est **interdite pour produire** le travail : le code à compléter, les observations et les conclusions doivent être les vôtres.

— Il est **interdit** de coller l'énoncé, le carnet ou les données dans une conversation avec un outil d'IA.

— La **déclaration** en fin de carnet est obligatoire, même si aucun outil n'a été utilisé : outil, question visée, ce qui a été demandé, lien de partage de la conversation.

Attention

Une déclaration absente ou fausse entraîne la note de **0** pour le travail.

7 Remise

— Le carnet complet, exécuté du début à la fin sans erreur, sur la branche principale de votre dépôt, intégré par une pull request.

— Date limite : **vendredi 23 octobre 2026, à 23 h 59**.

8 Barème

Élément évalué	Points
Section 1 — Découvrir les données : styles et mesures bien lus, dessins comparés	10
Section 2 — Supervisé : forêt correctement entraînée et évaluée, lecture critique des résultats	15
Section 3 — Non supervisé : effet de la mise à l'échelle compris, choix du nombre de groupes justifié, groupes bien décrits	25
Section 4 — Semi-supervisé : comparaison bien menée, erreurs bien expliquées	20
Section 5 — Conclusion : tableau juste, recommandation claire et appuyée sur les résultats	10
Qualité du carnet Jupyter : carnet propre, lisible, exécuté du début à la fin, observations bien rédigées	10
Utilisation de Git : travail par branches et pull requests, nomenclature vue en cours, contribution de chaque membre	10
Total	**100**

Les observations comptent dans les points de chaque section. Une observation absente, vague ou non appuyée sur les résultats fait perdre des points, même si le code fonctionne.